



KOLEGJI UBT

Shkenca Kompjuterike dhe Inxhinieri

**Analiza e Ndikimit të Lajmeve Financiare në Lëvizjen e
Aksioneve**

Lënda: Shkenca e të dhënave dhe Vizualizimi me Python

Profesori

Dr. Sc. Vehbi Neziri

Studenti

Ardian Asani
Djallon Pllana
Blend Fetahu
Lorik Hoxha
Bleon Sinani

Data: 15.05.2026

Tabela e përmbajtjes

1. Përmbledhje (abstract).....	4
2. Hyrje.....	5
2.1 Konteksti dhe Motivimi.....	5
2.2 Pyetjet Analitike	6
3. Metodologjia	7
3.1 Burimi dhe lloji i të dhënave	7
3.2 Procesi ETL dhe përgatitja e të dhënave	7
3.3 Analiza statistikore dhe modelimi	8
4. Analiza e të Dhënave.....	9
4.1 Statistikat Përshkruese.....	9
4.2 Kthimet Ditore dhe Testi Statistikor.....	9
5. Vizualizimi i të Dhënave.....	11
5.1 Seria Kohore e Çmimit të Mbylljes.....	11
5.2 Shpërndarja e Kthimeve Ditore sipas Label.....	11
5.3 Vizualizimet e Dashboard-it Streamlit	12
6. Rezultatet dhe Interpretimi	13
6.1 Gjetjet Statistikore	13
6.2 Performanca e Modelit Machine Learning.....	13
6.3 Backtesting dhe Kufizimet	14
7. Përfundimi dhe Rekomandimet.....	15
8. Referencat.....	16
9. Shtojca (Appendix).....	17
A.1 ETL Pipeline për përgatitjen e të dhënave.....	17
A.2 Llogaritja e kthimeve ditore dhe Welch t-test	18
A.3 TF-IDF dhe Logistic Regression	19
A.4 Logjika e Backtesting-ut.....	21

Lista e tabelave

Tabela 1. Përmbledhja e dataseve të përdorura në projekt dhe roli i tyre në analizën financiare dhe modelimin e të dhënave.	7
Tabela 2. Statistikat përshkruese të të dhënave financiare të DJIA.....	9
Tabela 3. Rezultatet e Welch t-test për kthimet ditore sipas Label.	10

Lista e figurave

<i>Figura 1. Lëvizja e çmimit të mbylles së indeksit DJIA me kalimin e kohës.....</i>	<i>11</i>
<i>Figura 2. Shpërndarja e kthimeve ditore të tregut sipas vlerës së Label.</i>	<i>12</i>

1. Përmbledhje (abstract)

Ky projekt fokusohet në analizimin e ndikimit të lajmeve financiare në lëvizjen e tregut aksionar, konkretisht indeksit Dow Jones Industrial Average (DJIA). Qëllimi kryesor i projektit është të vlerësohet nëse informacioni i publikuar në lajmet financiare mund të lidhet me ndryshimet ditore të tregut dhe të përdoret për analiza statistikore dhe modelim me Machine Learning.

Në projekt janë përdorur tre datasete kryesore të marra nga Kaggle, të cilat përfshijnë lajme financiare, të dhëna historike të DJIA dhe lajme nga Reddit. Fillimisht u realizua procesi ETL për pastrimin, transformimin dhe bashkimin e të dhënave duke përdorur Python dhe bibliotekat Pandas dhe NumPy. Më pas u realizua analiza statistikore dhe vizualizimi i të dhënave për të identifikuar modele dhe lidhje ndërmjet lajmeve dhe lëvizjes së tregut.

Për pjesën e modelimit u përdor TF-IDF për përpunimin e tekstit dhe algoritmi Logistic Regression për klasifikimin e ditëve pozitive dhe negative të tregut. Gjithashtu u realizuan vizualizime dhe analiza statistikore si histogramet, analiza e kthimeve ditore dhe Welch t-test.

Rezultatet treguan se ekziston një lidhje ndërmjet përmbajtjes së lajmeve financiare dhe lëvizjes së tregut aksionar, megjithëse tregjet financiare ndikohen edhe nga faktorë të tjerë ekonomikë dhe politikë. Projekti demonstroi përdorimin praktik të analizës së të dhënave, përpunimit të tekstit dhe Machine Learning në analizën financiare.

2. Hyrje

Tregjet financiare janë sisteme komplekse ku çmimet e aksioneve ndryshojnë vazhdimisht nën ndikimin e faktorëve ekonomikë, politikë dhe socialë. Investitorët dhe institucionet financiare analizojnë çdo ditë sasi të mëdha informacioni për të kuptuar drejtimin e tregut dhe për të marrë vendime investimi. Ndër faktorët më të rëndësishëm që ndikojnë në sjelljen e tregut janë lajmet financiare, raportet ekonomike, deklaratat politike dhe informacioni i publikuar në media dhe rrjete sociale [1].

Me zhvillimin e teknologjisë dhe rritjen e sasisë së të dhënave digjitale, analiza tradicionale financiare është kombinuar gjithnjë e më shumë me teknikat moderne të shkencës së të dhënave. Përpunimi i Gjuhës Natyrore (Natural Language Processing – NLP) dhe Machine Learning përdoren për të analizuar tekstin e lajmeve financiare dhe për të identifikuar modele që mund të lidhen me lëvizjen e tregut aksionar [2]. Ideja kryesore është se lajmet negative mund të ndikojnë në uljen e çmimeve të aksioneve, ndërsa lajmet pozitive mund të ndikojnë në rritjen e tyre. Megjithatë, tregjet financiare janë shumë dinamike dhe ndikohen nga faktorë të shumtë, prandaj analizimi i kësaj lidhjeje kërkon metoda statistikore dhe modele të përshtatshme të analizës së të dhënave.

Indeksi Dow Jones Industrial Average (DJIA) është një nga indeksët bursierë më të njohur në botë dhe përfaqëson performancën e 30 kompanive kryesore amerikane. Për shkak të rëndësisë së tij në tregjet financiare, DJIA përdoret shpesh si tregues i gjendjes së ekonomisë amerikane dhe reagimit të tregut ndaj ngjarjeve ekonomike dhe politike. Lëvizjet ditore të këtij indeksi pasqyrojnë sjelljen e investitorëve dhe reagimin e tregut ndaj informacionit të ri, gjë që e bën DJIA një subjekt të përshtatshëm për analizimin e ndikimit të lajmeve financiare në tregun aksionar.

Ky projekt është realizuar në kuadër të lëndës “Shkenca e të Dhënave dhe Vizualizimi me Python” dhe ka për qëllim demonstrimin praktik të teknikave të analizës së të dhënave në një problem real financiar. Projekti kombinon disa komponentë të rëndësishëm të Data Science, duke përfshirë procesin ETL, analizën statistikore, përpunimin e tekstit, modelimin me Machine Learning dhe vizualizimin interaktiv të të dhënave. Përmes këtij projekti synohet të analizohet nëse ekziston një lidhje ndërmjet lajmeve financiare dhe drejtimit të lëvizjes së tregut.

2.1 Konteksti dhe Motivimi

Motivimi kryesor i këtij projekti lidhet me rritjen e përdorimit të analizës së ndjenjave (sentiment analysis) në sektorin financiar. Institucionet financiare dhe kompanitë e investimeve përdorin sisteme automatike për analizimin e lajmeve dhe identifikimin e

sinjaleve që mund të ndikojnë në treg. Në vitet e fundit, analiza e lajmeve financiare është bërë një pjesë e rëndësishme e sistemeve moderne të tregtimit dhe vendimmarrjes financiare.

Ky projekt synon të eksplorojë këtë koncept në nivel akademik duke përdorur dataset publike dhe mjete open-source për analizën e të dhënave. Gjithashtu, projekti shërben si rast praktik për aplikimin e koncepteve të mësuara gjatë lëndës, si pastrimi dhe manipulimi i të dhënave me Pandas, analiza statistikore me NumPy dhe SciPy, vizualizimi me Matplotlib dhe Plotly, si dhe ndërtimi i modeleve Machine Learning me Scikit-learn dhe dashboard-eve interaktive me Streamlit.

Një nga sfidat kryesore të projektit ishte fakti se të dhënat tekstuale janë të pastruara dhe shpesh përmbajnë karaktere të panevojshme, formate të ndryshme dhe informacione jo relevante. Gjithashtu, tregjet financiare ndikohen nga shumë faktorë ekonomikë dhe politikë, gjë që e bën të vështirë parashikimin e saktë të lëvizjes së tregut vetëm bazuar në lajme financiare.

2.2 Pyetjet Analitike

Ky projekt synon të japë përgjigje për pyetjet e mëposhtme analitike:

1. A ekziston ndryshim statistikor i rëndësishëm ndërmjet kthimeve ditore të DJIA në ditët me Label = 1 dhe Label = 0?
2. A mund të përdoret teksti i lajmeve financiare për të parashikuar drejtimin e lëvizjes së tregut?
3. Sa efektiv është modeli Logistic Regression i trajnuar mbi TF-IDF features të lajmeve?
4. Çfarë rezultatesh prodhon modeli kur përdoret në një simulim të thjeshtë backtesting?

Të gjitha pyetjet trajtohen përmes analizës statistikore dhe modelimit të të dhënave, duke u bazuar në rezultatet e nxjerra nga datasetet e përdorura në projekt.

3. Metodologjia

3.1 Burimi dhe lloji i të dhënave

Në këtë projekt janë përdorur të dhëna financiare dhe tekstuale të marra nga platforma Kaggle. Datasetet kryesore përfshijnë lajme financiare ditore, të dhëna historike të indeksit Dow Jones Industrial Average (DJIA) dhe lajme nga Reddit. Të dhënat përmbajnë si informacion tekstual, pra tituj lajmesh, ashtu edhe të dhëna numerike si çmimet Open, High, Low, Close dhe Volume. Kombinimi i këtyre të dhënave mundëson analizimin e lidhjes ndërmjet lajmeve financiare dhe lëvizjes së tregut aksionar.

Dataseti kryesor përmban 25 lajmet kryesore për secilën ditë tregtimi dhe një kolonë Label, e cila tregon nëse tregu ka pasur rritje apo rënie gjatë asaj dite. Përveç këtij dataseti, janë përdorur edhe të dhëna historike të indeksit DJIA dhe një dataset shtesë me lajme nga Reddit.

Tabela 1. Përmbledhja e dataseteve të përdorura në projekt dhe roli i tyre në analizën financiare dhe modelimin e të dhënave.

Dataset	Përshkrimi	Numri i rreshtave
Combined_News_DJIA	Lajme financiare dhe label i tregut	1989
upload_DJIA_table	Të dhënat historike të DJIA	1989
RedditNews	Lajme financiare nga Reddit	73608

3.2 Procesi ETL dhe përgatitja e të dhënave

Procesi i punës fillon me fazën ETL, e cila përfshin ngarkimin, pastrimin, transformimin dhe ruajtjen e të dhënave. Fillimisht datasetet u ngarkuan në Python duke përdorur bibliotekën Pandas dhe funksionin `read_csv()`. Kolonat e datës u konvertuan në format datetime për të mundësuar bashkimin korrekt të dataseteve sipas kolonës **Date**.

Teksti i lajmeve u pastrua duke larguar karaktere të panevojshme dhe prefikse si **b'...**, të cilat ishin rezultat i mënyrës së ruajtjes së të dhënave në datasetin origjinal. Gjithashtu, u trajtuan vlerat mungesë në kolonat e lajmeve dhe u eliminuan duplikatat për të shmangur përsëritjen e të dhënave gjatë analizës.

Pas pastrimit, datasetet u bashkuan duke përdorur metodën `inner join` mbi kolonën `Date`, në mënyrë që të ruheshin vetëm ditët që kishin njëkohësisht lajme dhe të dhëna financiare. Dataseti i bashkuar u nda më pas në `train` dhe `test` sipas vitit, ku të dhënat para vitit 2015 u

përdorën për trajnim, ndërsa të dhënat nga viti 2015 e tutje për testim. Kjo metodë u zgjodh për të ruajtur renditjen kohore të të dhënave dhe për të shmangur rrjedhjen e informacionit nga e ardhmja.

3.3 Analiza statistikore dhe modelimi

Për analizën statistikore u përdorën bibliotekat **Pandas**, **NumPy** dhe **SciPy**. Kthimet ditore të tregut u llogaritën me funksionin **pct_change()** mbi kolonën Close, ndërsa Welch t-test u përdor për të krahasuar kthimet mes ditëve me **Label = 0** dhe **Label = 1**.

Për vizualizimin e të dhënave u përdorën Matplotlib, Seaborn dhe Plotly, të cilat mundësuan krijimin e grafikëve dhe analizave vizuale të tregut financiar. Për pjesën e modelimit u përdor biblioteka Scikit-learn, ku teksti i lajmeve u transformua në të dhëna numerike përmes TF-IDF Vectorizer dhe më pas u përdor algoritmi Logistic Regression për klasifikimin e ditëve pozitive dhe negative të tregut.

Kjo metodologji u zgjodh sepse kombinon përgatitjen e të dhënave, analizën statistikore, vizualizimin dhe modelimin në një proces të plotë të analizës së të dhënave dhe Machine Learning.

4. Analiza e të Dhënave

4.1 Statistikat Përshkruese

Dataset-i i DJIA përmban 1,989 rreshta me të dhëna ditore nga viti 2008 deri në vitin 2016. Tabela 2 paraqet statistikat kryesore përshkruese për variablat financiare kryesore.

Tabela 2. Statistikat përshkruese të të dhënave financiare të DJIA.

Variabla	Mean	Min	Max	Std Dev
Open	13,459.12	6,547.01	18,315.06	3,143.28
High	13,541.30	6,709.61	18,351.36	3,136.27
Low	13,372.93	6,469.95	18,272.56	3,150.42
Close	13,463.03	6,547.05	18,312.39	3,144.01
Volume	162,810,000	8,410,000	674,920,000	93,923,430

Vlerat mesatare (Mean) të Open, High, Low dhe Close janë shumë afër njëra-tjetrës (rreth 13,400–13,550 pikë), gjë që tregon konsistencë të brendshme të të dhënave. Devijimi standard (Std Dev) prej rreth 3,140 pikësh tregon variabilitet të lartë gjatë periudhës së analizuar, duke reflektuar luhatjet e rëndësishme që ka pasur DJIA gjatë krizës financiare të viteve 2008–2009 dhe rimëkëmbjes së mëpasshme. Vlera minimale prej rreth 6,500 pikësh korrespondon me periudhën e krizës, ndërsa maksimumi prej rreth 18,300 pikësh reflekton nivelet e arritura deri në fund të periudhës së analizës.

Volumi i tregimit paraqet variabilitet edhe më të madh. Devijimi standard prej rreth 93.9 milion është relativisht i lartë krahasuar me mesataren prej 162.8 milion, duke treguar se ekzistojnë ditë me aktivitet shumë të lartë ose shumë të ulët tregtimi. Këto ndryshime zakonisht lidhen me ngjarje të rëndësishme ekonomike, politike ose financiare që ndikojnë në sjelljen e investitorëve dhe tregut aksionar.

4.2 Kthimet Ditore dhe Testi Statistikor

Kthimi ditor (daily return) llogaritet si ndryshimi përqindjesor i çmimit të mbylljes nga dita paraardhëse në ditën aktuale. Kjo është një nga metrikat standarde që përdoret në analizën financiare për matjen e performancës ditore të një aktivi financiar. Pas llogaritjes, kthimet u ndanë në dy grupe bazuar në vlerën e kolonës **Label**: grupi **Label = 0** përfaqëson ditët kur tregu u ul ose mbeti i njëjtë, ndërsa grupi **Label = 1** përfaqëson ditët kur tregu u rrit.

Për të analizuar ndryshimin ndërmjet dy grupeve u përdor **Welch t-test**. Hipoteza zero e testit është:

$H_0: \mu_0 = \mu_1$

Kjo hipotezë nënkupton se nuk ekziston ndryshim statistikisht i rëndësishëm ndërmjet kthimeve mesatare të dy grupeve. Rezultatet e testit paraqiten në Tabelën 3.

Tabela 3. Rezultatet e Welch t-test për kthimet ditore sipas Label.

Grupi	n	Mesatare e kthimit	p-vlerë
Label = 0 (tregu u ul)	923	-0.8437%	$\approx 3.79 \times 10^{-228}$
Label = 1 (tregu u rrit)	1,065	+0.7860%	(e njëjtë për grupin)

P-vlera prej $\approx 3.79 \times 10^{-228}$ është jashtëzakonisht e vogël dhe tejkalon me shumë prapun konvencional $\alpha = 0.05$. Kjo do të thotë se hipoteza zero refuzohet me siguri shumë të lartë dhe ekziston ndryshim statistikisht i rëndësishëm ndërmjet kthimeve ditore të grupeve Label = 0 dhe Label = 1.

Ditët me Label = 1 paraqesin kthime mesatare pozitive, ndërsa ditët me Label = 0 lidhen më shumë me kthime negative ose më të ulëta të tregut. Ky rezultat mbështet hipotezën se etiketa e tregut (Label) ka lidhje statistikore me drejtimin e lëvizjes së tregut brenda datasetit të analizuar.

Në përgjithësi, analiza statistikore tregon se të dhënat financiare të përdorura në projekt përmbajnë variabilitet të konsiderueshëm dhe modele të dallueshme ndërmjet ditëve pozitive dhe negative të tregut. Këto rezultate krijojnë bazën për analizat e mëtejshme të vizualizimit dhe modelimit me Machine Learning.

5. Vizualizimi i të Dhënave

Vizualizimi i të dhënave ka rol të rëndësishëm në këtë projekt, sepse ndihmon në interpretimin më të qartë të rezultateve statistikore dhe të sjelljes së tregut gjatë periudhës së analizuar. Grafikët statikë janë krijuar me Matplotlib dhe Seaborn nga skedari analysis.py, ndërsa vizualizimet interaktive janë realizuar me Plotly në dashboard-in e ndërtuar me Streamlit.

5.1 Seria Kohore e Çmimit të Mbylljes

Figura 1 paraqet lëvizjen e çmimit të mbylljes (Close) të indeksit DJIA gjatë periudhës 2008–2016. Ky grafik është i rëndësishëm sepse mundëson identifikimin vizual të trendeve afatgjata, periudhave të rënies dhe fazave të rimëkëmbjes së tregut.




Figura 1. Lëvizja e çmimit të mbylles së indeksit DJIA me kalimin e kohës

Nga Figura 1 vërehet një rënie e mprehtë e indeksit rreth viteve 2008–2009, periudhë që lidhet me krizën financiare globale. Pas kësaj periudhe, DJIA shfaq një trend gradual rritës, me disa luhajtje të ndërmjetme. Ky grafik ndihmon në kuptimin e kontekstit historik të të dhënave dhe tregon se periudha e analizuar përmban faza të ndryshme të tregut.

5.2 Shpërndarja e Kthimeve Ditore sipas Label

Figura 2 paraqet histogramin e kthimeve ditore të DJIA, të ndarë sipas vlerës së kolonës Label. Ky grafik përdoret për të krahasuar vizualisht shpërndarjen e kthimeve për ditët kur tregu është rritur dhe për ditët kur tregu është ulur ose ka mbetur i njëjtë.




Figura 2. Shpërndarja e kthimeve ditore të tregut sipas vlerës së Label.

Nga Figura 2 vërehet se shpërndarja për **Label = 1** është më e zhvendosur drejt vlerave pozitive, ndërsa shpërndarja për **Label = 0** është më e lidhur me vlera negative ose më të ulëta të kthimit. Megjithatë, ekziston mbivendosje ndërmjet dy shpërndarjeve, gjë që tregon se ndarja mes ditëve pozitive dhe negative nuk është gjithmonë e plotë. Kjo e bën problemin e parashikimit më sfidues.

5.3 Vizualizimet e Dashboard-it Streamlit

Përveç grafikëve statikë, projekti përfshin edhe një dashboard interaktiv të ndërtuar me Streamlit dhe Plotly. Ky dashboard mundëson eksplorimin e të dhënave përmes filtrimit sipas datës dhe vlerës së Label, si dhe shfaqjen e grafikëve interaktivë për çmimin e mbylljes, kthimet ditore dhe volatilitetin e tregut.

Në dashboard janë përfshirë edhe vizualizime të lidhura me modelin Machine Learning, si matrica e konfuzionit dhe kurba e kapitalit nga backtesting-u i thjeshtë. Këto vizualizime ndihmojnë në kuptimin e performancës së modelit dhe mënyrës se si sinjalet e tij mund të përdoren për simulimin e një strategjie të thjeshtë tregtimi. Në këtë mënyrë, vizualizimi nuk shërben vetëm për paraqitje grafike, por edhe për interpretimin praktik të rezultateve të analizës.

6. Rezultatet dhe Interpretimi

Rezultatet e projektit tregojnë ekzistencën e një lidhjeje statistikore ndërmjet lajmeve financiare dhe lëvizjes ditore të indeksit DJIA. Gjetjet kryesore të projektit lidhen me analizën statistikore të të dhënave, performancën e modelit Machine Learning dhe simulimin e strategjisë së thjeshtë të backtesting-ut.

6.1 Gjetjet Statistikore

Një nga rezultatet më të rëndësishme të projektit është rezultati i Welch t-test, i cili prodhoi një p-vlerë $\approx 3.79 \times 10^{-228}$. Kjo vlerë është shumë më e vogël se niveli standard i rëndësisë statistikore $\alpha = 0.05$, gjë që tregon se ekziston ndryshim statistikisht i rëndësishëm ndërmjet kthimeve mesatare të grupeve **Label = 0** dhe **Label = 1**.

Ditët me **Label = 1** paraqesin kthime mesatare pozitive, ndërsa ditët me **Label = 0** lidhen më shumë me kthime negative ose më të ulëta të tregut. Ky rezultat tregon se ndarja e të dhënave sipas Label reflekton qartë ndryshimin e drejtimit të tregut brenda datasetit të analizuar.

Gjithashtu, analiza statistikore tregoi se tregu financiar ka variabilitet të konsiderueshëm gjatë periudhës së analizuar. Devijimi standard relativisht i lartë i çmimeve dhe volumit të tregtimit tregon praninë e periudhave me volatilitet të lartë, sidomos gjatë krizës financiare globale të viteve 2008–2009.

6.2 Performanca e Modelit Machine Learning

Për pjesën e modelimit u përdor algoritmi Logistic Regression i kombinuar me TF-IDF Vectorizer për përpunimin e lajmeve financiare. Modeli përdor 25 lajmet kryesore të çdo dite për të klasifikuar nëse tregu do të ketë rritje apo rënie.

Rezultatet tregojnë se modeli arrin performancë të pranueshme për një problem kompleks si parashikimi i drejtimit të tregut financiar. Përmbajtja tekstuale e lajmeve përmban informacione që mund të përdoren për të identifikuar modele dhe sinjale të caktuara të tregut, megjithëse parashikimi i plotë i tregut mbetet një problem shumë i vështirë për shkak të faktorëve të shumtë ekonomikë dhe politikë që ndikojnë në të.

Performanca e modelit ndikohet nga cilësia e lajmeve, parametrat e TF-IDF dhe kufizimet e datasetit. Të dhënat e përdorura përfshijnë vetëm lajme në gjuhën angleze dhe të lidhura me DJIA, gjë që kufizon aftësinë e modelit për t'u përgjithësuar në tregje ose periudha të tjera.

6.3 Backtesting dhe Kufizimet

Projekti përfshin edhe një simulim të thjeshtë të backtesting-ut, ku strategjia gjeneron sinjale blerjeje ose shitjeje bazuar në parashikimin e modelit. Kurba e kapitalit e paraqitur në dashboard tregon mënyrën se si do të kishte performuar strategjia gjatë periudhës së testimit.

Megjithatë, backtesting-u i realizuar ka disa kufizime të rëndësishme. Simulimi supozon ekzekutim të menjëhershëm të urdhrave dhe nuk përfshin faktorë realë të tregut si slippage, likuiditeti ose vonesat e ekzekutimit. Gjithashtu, analiza është e kufizuar vetëm në indeksin DJIA dhe nuk përfshin variabla makroekonomike si normat e interesit, inflacioni ose indikatorë të tjerë ekonomikë.

Një tjetër kufizim është fakti se modeli i përdorur është relativisht i thjeshtë krahasuar me modelet moderne të inteligjencës artificiale dhe përpunimit të gjuhës natyrore. Pavarësisht kësaj, projekti demonstroi se teknikat e NLP dhe Machine Learning mund të përdoren me sukses për analizimin e lajmeve financiare dhe identifikimin e sinjaleve statistikore të lidhura me lëvizjen e tregut.

Në përgjithësi, rezultatet e projektit tregojnë potencialin që kanë analizat e të dhënave dhe përpunimi i tekstit në analizën financiare moderne, duke demonstruar një kombinim praktik të statistikës, vizualizimit dhe Machine Learning në një problem real të Data Science.

7. Përfundimi dhe Rekomandimet

Ky projekt realizoi me sukses një proces të plotë të analizës së të dhënave financiare duke kombinuar ETL, analizë statistikore, Machine Learning dhe vizualizim interaktiv. Qëllimi kryesor i projektit ishte analizimi i lidhjes ndërmjet lajmeve financiare dhe lëvizjes ditore të indeksit DJIA, ndërsa rezultatet treguan se ekziston një lidhje statistikisht e rëndësishme ndërmjet këtyre faktorëve brenda datasetit të analizuar.

Gjatë projektit u realizua pastrimi dhe bashkimi i të dhënave nga disa burime të ndryshme, llogaritja e kthimeve ditore dhe analiza statistikore me Welch t-test. Gjithashtu u ndërtua një model Machine Learning me TF-IDF dhe Logistic Regression për klasifikimin e ditëve pozitive dhe negative të tregut bazuar në lajmet financiare. Përveç analizës statistikore dhe modelimit, projekti përfshiu edhe krijimin e një dashboard-i interaktiv me Streamlit dhe Plotly për vizualizimin e rezultateve dhe simulimin e një strategjie të thjeshtë tregtimi.

Rezultatet treguan se teknikat e përpunimit të tekstit dhe analizës së të dhënave mund të përdoren për të identifikuar modele të caktuara në tregjet financiare. Megjithatë, projekti tregoi gjithashtu se parashikimi i tregut mbetet një problem kompleks për shkak të faktorëve të shumtë ekonomikë, politikë dhe psikologjikë që ndikojnë në sjelljen e investitorëve.

Për përmirësime të mëtejshme rekomandohet përdorimi i të dhënave më të reja dhe zgjerimi i analizës në tregje ose aksione të tjera financiare. Gjithashtu, modele më të avancuara të NLP-së si BERT ose FinBERT mund të ofrojnë rezultate më të sakta në analizën e lajmeve financiare. Një tjetër përmirësim do të ishte ndërtimi i një sistemi automatik për mbledhjen e lajmeve në kohë reale dhe implementimi i një backtesting-u më realist me faktorë si slippage, latency dhe kostot reale të tregtimit.

Në përgjithësi, projekti arriti objektivat e tij akademike dhe demonstroi përdorimin praktik të teknikave moderne të Data Science në analizën financiare. Projekti kombinon statistikën, vizualizimin, përpunimin e tekstit dhe Machine Learning në një problem real dhe paraqet një bazë të mirë për zhvillime dhe analiza më të avancuara në të ardhmen.

8. Referencat

[1] Python Software Foundation. *Python Documentation*. Disponueshme në: <https://docs.python.org/>

[2] Kaggle. *Financial News and DJIA Datasets*. Disponueshme në: <https://www.kaggle.com/datasets>

[3] McKinney, W. (2018). *Python for Data Analysis*. O'Reilly Media.

[4] Scikit-learn Developers. *Scikit-learn Documentation*. Disponueshme në: <https://scikit-learn.org/>

[5] Streamlit Developers. *Streamlit Documentation*. Disponueshme në: <https://docs.streamlit.io/>

9. Shtojca (Appendix)

Në këtë seksion paraqiten fragmentet kryesore të kodit të përdorura gjatë realizimit të projektit. Kodi është organizuar sipas funksionaliteteve kryesore të sistemit, duke përfshirë procesin ETL, analizën statistikore, modelimin me Machine Learning dhe logjikën e backtesting-ut. Fragmentet e mëposhtme paraqesin pjesët më të rëndësishme të implementimit praktik të projektit.

A.1 ETL Pipeline për përgatitjen e të dhënave

```
# ETL Pipeline – DataPreparation/dataPreparation.py

import pandas as pd

djia_news = pd.read_csv("rawData/Combined_News_DJIA.csv")
djia_table = pd.read_csv("rawData/upload_DJIA_table.csv")
reddit = pd.read_csv("rawData/RedditNews.csv")

# Pastrimi i tekstit

news_cols = [c for c in djia_news.columns if c.startswith("Top")]

for col in news_cols:
    djia_news[col] = djia_news[col].str.strip("b'\"")

# Konvertimi i datës dhe heqja e duplikatëve

djia_news["Date"] = pd.to_datetime(djia_news["Date"])
djia_table["Date"] = pd.to_datetime(djia_table["Date"])

djia_news.drop_duplicates(subset=["Date"], inplace=True)
```

```

# Bashkimi i dataset-eve

merged = djia_news.merge(djia_table, on="Date", how="inner")

merged.to_csv(
    "cleanedData/Combined_News_DJIA_Merged.csv",
    index=False
)

# Ndarja train/test sipas vitit

train = merged[merged["Date"].dt.year < 2015]
test = merged[merged["Date"].dt.year >= 2015]

train.to_csv("cleanedData/df_train.csv", index=False)
test.to_csv("cleanedData/df_test.csv", index=False)

```

A.2 Llogaritja e kthimeve ditore dhe Welch t-test

```

# analysis.py

from scipy import stats

# Llogaritja e kthimeve ditore

df["daily_return"] = df["Close"].pct_change()

# Ndarja e grupeve sipas Label

g0 = df[df["Label"] == 0]["daily_return"].dropna()
g1 = df[df["Label"] == 1]["daily_return"].dropna()

```

```

# Welch t-test

t_stat, p_val = stats.ttest_ind(

    g1,

    g0,

    equal_var=False

)

# Ruajtja e rezultateve

with open("outputs/summary.txt", "w") as f:

    f.write(

        "Return difference test "

        "(Label=1 vs Label=0)\n"

    )

    f.write(f"n0={len(g0)}, mean0={g0.mean():.6f}\n")

    f.write(f"n1={len(g1)}, mean1={g1.mean():.6f}\n")

    f.write(f"p-value={p_val:.5e}\n")

```

A.3 TF-IDF dhe Logistic Regression

```

# model.py

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline

# Bashkimi i lajmeve në një tekst të vetëm

def build_text(row, cols):

    return " ".join(

```

```

        str(row[c]) for c in cols if pd.notna(row[c])

    )

df["text"] = df.apply(
    lambda r: build_text(r, news_cols),
    axis=1
)

# Train/Test split
train_df = df[df["Date"].dt.year < 2015]
test_df = df[df["Date"].dt.year >= 2015]

# TF-IDF + Logistic Regression
pipeline = Pipeline([
    (
        "tfidf",
        TfidfVectorizer(
            max_features=5000,
            stop_words="english"
        )
    ),
    (
        "clf",
        LogisticRegression(max_iter=1000)
    ),
])

pipeline.fit(train_df["text"], train_df["Label"])
preds = pipeline.predict(test_df["text"])

```

A.4 Logjika e Backtesting-ut

```
# Fragment nga app.py
equity = [starting_equity]
position = 0 # 1 = long, 0 = flat
for signal, ret in zip(signals, daily_returns):
    # Hapja e pozicionit
    if signal == 1 and position == 0:
        position = 1
        equity.append(
            equity[-1] * (1 - transaction_cost)
        )
    # Mbyllja e pozicionit
    elif signal == 0 and position == 1:
        position = 0
        equity.append(
            equity[-1] * (1 - transaction_cost)
        )
    # Përditësimi i kapitalit
    elif position == 1:
        equity.append(
            equity[-1] * (1 + ret)
        )
    else:
        equity.append(equity[-1])
```

